

Evaluation of the agent

"Once you have implemented your agent, you must evaluate how well it performs.

Create a small evaluation set with at least **10 test prompts**. The prompts should include different combinations of:

- broad topics
- narrow topics
- before / after / exact year constraints
- minimum citation constraints
- cases where no good paper can be found
- ambiguous user requests

For each test prompt, evaluate whether the agent:

- found a relevant paper
- respected the year constraint
- respected the citation constraint
- provided a valid source
- avoided hallucinated information
- gave a useful explanation

You must also briefly research how AI agents can be evaluated and use that to justify your evaluation method.

Your evaluation does not need to be perfect, but it must be systematic."

Prompt	Prompt Type	Relevant Paper	Year Constraint	Citation Constraint	Valid Source	No Hallucination	Useful Explanation
1: Find a research paper specifically about convolutional neural networks for medical image classification.	Small emne	"Scientific Machine Learning Through Physics-Informed Neural Networks: Where we are and What's Next",	2022	2115	"https://link.springer.com/content/pdf/10.1007/s10915-022-01939-z.pdf"	Yes	Yes
2: Find a highly cited research paper about machine learning.	Bredt Emne	"Opinion Paper: 'So what if ChatGPT wrote it?' Multidisciplinary perspectives on opportunities, challenges and implications of generative conversational AI for research, practice and policy"	2023	3462	The link does not work. But the article is real.	Yes	Yes
3: Find a research paper about neural networks	Før et beste mt år 2010	The PRISMA Statement for Reporting	2009	27759	Ja	Ja	Ja

		Systematic Reviews and Meta-Analyses of Studies That Evaluate Health Care Interventions: Explanation and Elaboration					
4: Find a research paper about reinforcement learning	Eksakt år 2018	MizAR 60 for Mizar 50	2023 – ikke overholdt	75280	Ja	Ja	Ja
5: Find a research paper about large language models	Efter et bestemt år 2022	MizAR 60 for Mizar 50	2023	75280	Ja	Ja	Ja
6: Find a research paper about deep learning	Minimum citation constraint 5000 citations.	ImageNet classification with deep convolutional neural networks	2017	75672	Ja	Ja	Ja
7: Find a paper about computer vision	Kombination (år + citationer) efter 2015 med mindst	ImageNet classification with deep convolutional neural networks	2017	75672 – ikke overholdt	Ja	Ja	Ja

	76000 citations.						
8: Find a research paper about using AI to predict lottery numbers accurately.	Edge case (ingen gode papers)	The AI gambit: leveraging artificial intelligence to combat climate change-opportunities, challenges, and recommendations	2021	408	Ja	Ja	Ja men den har ikke fundet et relevant paper
9: Find a good paper about AI.	Ambiguous request	MizAR 60 for Mizar 50	2023	75280	Ja	Ja	Ja, men giver gen MiAR paperet, som den er meget glad ved
10: Find a research paper about quantum machine learning applied to agriculture	Meget småt og med svær constraint. Før 2005 og med mindst 100 citationer.	Artificial Intelligence (AI): Multidisciplinary perspectives on emerging challenges, opportunities, and agenda for research, practice and policy	2019 -ikke overholdt.	3896 - ikke overholdt.	Ja	Ja	Ja, relevant for paperet men ikke for prompten, da paperet ikke er relevant.

Evaluering og refleksion

Hvad fungerede godt?

Agenten fandt kun artikler, der faktisk eksisterer. Mistral holdt sig til det, den fik i prompten, og opfandt ikke nye oplysninger. Beskrivelserne af artiklerne var generelt ret skarpe og velformulerede. De før- og efter-års constraints virkede fint, så længe vi tastede dem direkte ind i konsollen.

Hvad drillede?

Agenten havde tydeligt svært ved at følge de eksakte årangivelser, især hvis vi skrev dem i prompten i stedet for at smide dem direkte ind som input i konsollen. Så constraintsystemet fungerede egentlig kun, når vi skrev dem eksplicit i konsollen. Men ikke med et eksakt år.

Derudover blev artiklen gentaget hyppigt ("MizAR 60 for Mizar 50"), hvilket kan indikere en bias i ranking eller begrænset diversitet i resultaterne.

Hallucinerede LLM'en på noget tidspunkt?

Nej. Mistral holdt sig til de data, den fik i prompten og tilføjede ikke noget ekstra.

Hvad ville vi gøre bedre med mere tid?

Vi ville bruge OpenAlex's API-filters, f.eks. filter=publication_year:2018 direkte i URL'en, så årstallet matcher og ikke bare næsten gør. Og vi ville gerne trække constraints mere sikkert ud fra prompten, så det ikke afhænger af, at vi skriver det manuelt ind i konsollen.